

Step by step rekonstrukcija chain linked volume-ov - letnih

download podatkov iz eurostata

Za testiranje izberemo podatke za dodano vrednost za Slovenijo za sektorja M in N, in objavljen agregat M_N. Drugače je tukaj link na tabelo nama_10_a64: klik

- CP_MEUR = constant prices (mio eur)
- PYP_MEUR = previous year's prices (mio eur)
- CLV10_MEUR = chain linked volumes 2010 (mio eur)

```
# download podatkov
raw <- get_eurostat("nama_10_a64",
                    filters = list(
                      geo = "SI", # tuki zamenjaj državo ali pa EU27_2020, EU15, EA
                      time = 1995:2023,
                      na_item = "B1G", # Value added, gross
                      unit = c("CP_MEUR", "PYP_MEUR", "CLV10_MEUR"),
                      nace_r2 = c("M", "N", "M_N")))

```

Znebimo se odvečne robe, preimenujemo spremenljivke in gremo v malo bolj wide tabelo:

```
VA <- raw |>
  mutate(year = year(time), .keep = "unused") |>
  select(-freq, -na_item, -geo) |>
  filter(!is.na(values)) |>
  pivot_wider(names_from = unit, values_from = values) |>
  rename(current_prices = CP_MEUR,
         previous_years_prices = PYP_MEUR,
         clv_eurostat = CLV10_MEUR)
head(VA)
```

```
## # A tibble: 6 x 5
##   nace_r2 year current_prices clv_eurostat previous_years_prices
##   <chr>   <dbl>         <dbl>         <dbl>         <dbl>
## 1 M_N    1995          965.          2075.          NA
## 2 M_N    1996         1017.          2029.          944.
## 3 M_N    1997         1069          2008.         1007.
## 4 M_N    1998         1204.          2025.         1078.
## 5 M_N    1999         1338.          2152.         1280
## 6 M_N    2000         1390.          2299.         1429.
```

preverjanje teoretskih predpostavk

OK, če prav razumem je osnovna ideja to, da chain linked volumes niso aditivni, medtem ko stalne cene in cene prejšnjega leta so.

Tako da najprej preverimo do katere mere je to res pri teh podatkih: ali se M in N pravilno seštejejo:

```
test_additivity <- VA |>
  mutate(group = ifelse(nace_r2 == "M_N", "orig", "aggr")) |>
  group_by(group, year) |>
  summarise(across(where(is.numeric), \ (x) sum(x, na.rm = TRUE))) |>
  pivot_wider(names_from = group,
              values_from = -c(year, group),
              names_glue = "{.value}_{group}") |>
  mutate(across(ends_with("_aggr"),
                \ (x) x - get(sub("_aggr$", "_orig", cur_column()))),

```

```

      .names = "{sub('_aggr$', '_diff', .col)}"),
      .keep = "unused")

```

```
head(test_additivity)
```

```

## # A tibble: 6 x 4
##   year current_prices_diff clv_eurostat_diff previous_years_prices_diff
##   <dbl>         <dbl>         <dbl>         <dbl>
## 1 1995             0             13.3             0
## 2 1996             0             12.5             0
## 3 1997        -0.100             11.5             0
## 4 1998             0              9             0
## 5 1999             0             9.5             0
## 6 2000             0            13.7             0

```

OK, to izgleda prilično OK.

zdej pa zares

Tale pipe naredi naslednje stvari:

agregacija

- najprej seštejemo M+N - dodamo novo spremenljivko `group`, ki ima vrednost `orig` za vrednosti iz Eurostatove M_N vsote in `aggr` za naše agregacije

koeficient rasti

- potem ta enostaven del: izračunamo koeficient rasti oz. `growth_factor`, ki je razmerje med letošnjo DV v lanskih cenah in lansko DV v tekočih cenah.
- edge case - to nisem čist ziher kaj narest z NA za prvo leto, zato ga spremenim v 1?

veriženje

- naredim dve vmesni spremenljivki: `chain_forward` in `chain_backward`, ki v eno ali drugo smer množita oz. delita zaporedne koeficiente rasti (zaradi teh `cumprod`-ov nočeš imeti NA-jev nikjer v seriji)
- potem jih združim, tako da za ref leto 2010 dam indeks 1, za nazaj je `backward` veriga in za naprej je `forward` veriga.
- na koncu množim verižen indeks s tekočimi cenami, da dobimo izračunan naš chain linked volume - `umar_chained_value`

V tabeli `calc` so zdej vsi ti izračuni:

```

ref_year <- 2010
calc <- VA |>
  mutate(group = ifelse(nace_r2 == "M_N", "orig", "aggr")) |>
  group_by(group, year) |>
  summarise(across(where(is.numeric), \(x) sum(x, na.rm = TRUE))) |>
  mutate(growth_factor = previous_years_prices / lag(current_prices),
         growth_factor = ifelse(is.na(growth_factor), 1, growth_factor),
         chain_forward = cumprod(growth_factor),
         chain_backward = rev(cumprod(rev(1/growth_factor))),
         chained_index = case_when(
           year > ref_year ~ chain_forward / chain_forward[year == ref_year],
           year == ref_year ~ 1,
           year < ref_year ~ chain_backward[row_number() + 1] /
             chain_backward[year == ref_year + 1]),
         clv_umar = current_prices[year == ref_year] * chained_index)

```

OK, zdej pa spucamo to tabelo in gremo primerjat naše izračune z Eurostatovimi:

```
final <- calc |>
  select(group, year, clv_eurostat, clv_umar) |>
  pivot_wider(names_from = group,
              values_from = c(clv_eurostat, clv_umar))
head(final)
```

```
## # A tibble: 6 x 5
##   year clv_eurostat_aggr clv_eurostat_orig clv_umar_aggr clv_umar_orig
##   <dbl>         <dbl>         <dbl>         <dbl>         <dbl>
## 1  1995           2088           2075.           2075.           2075.
## 2  1996           2041.           2029.           2029.           2029.
## 3  1997           2020           2008.           2009.           2009.
## 4  1998           2034.           2025.           2025.           2025.
## 5  1999           2162.           2152.           2152.           2152.
## 6  2000           2313           2299.           2299.           2299.
```


rezultati!

In to zgleda kot da je približno prav.. Se pravi :

- referenčna pravilna vrednost je `clv_eurostat_orig`, to je Eurostat naračunal za `M_N`
- en test, da imam pravilen izračun chain linked values, je `clv_umar_orig`, torej naš izračun iz objavljenih `M_N` agregatov za tekoče in lanske cene (rdeča črta)
- glavni rezultat pa je `clv_umar_aggr`, ki je naš izračun iz agregatov `M+N`, ki jih mi seštejemo iz tekočih in lanskih cen (zeleni črta)

Razliki za ti dve seriji sta na prvem grafu levo.

Za boljšo predstavbo pa še drugi graf, kjer je zraven (črno) še razlika med referenčno vrednostjo in nepravilnim izračunom, kjer seštevamo sicer neaditivne vrednosti CLV za $M + N$



Zdej ne vem, meni to zgleda good enough. V vsakem primeru mnogo bolje od tega, kar smo delali zdaj. Dodam pa caveat, da sem na hitro gledala kako to deluje pri ta velikih agregacijah, npr. seštevaje EU15 držav, in da je tam mnogo bolj messy, ker se tam niti tekoče cene niti približno prav ne seštevajo, tako da že osnovne predpostavke za ta izračun ne držijo.. Bom naredila še write-up tega in dodala v dokumentacijo, ampak mislim, da je bistvo te vaje, da je ta izračun pravilen in v vsakem primeru bolj pravilen od seštevaja neaditivnih vrednosti, tudi če pri nekaterih agregacijah ne bo bistveno bolj pravilen?

Pol moram pa še četrletja zvadit...